

Разведочный анализ данных (EDA)

891

пассажир, 1 строка = 1 человек

12

столбцов

Survived

цель: выжил или нет

02 Первый взгляд на данные

77%

Cabin почти пустой:
687 из 891

ЕЩЁ ПРОПУСКИ

Age 177 (20%)



Embarked 2



Повторов строк: 0

СТОЛБЦЫ

Числа Age, Fare, SibSp, Parch

Категории Pclass, Sex, Embarked

Все разные Name, Ticket

Номер PassengerId

03 Возраст и цена билета

ВЫБРОСЫ ПО 1,5 IQR

116


в Fare

11

в Age


Ничего не удалял

Гистограмма Age



Чаще от 20 до 40 лет, середина 28

Boxplot Age



Выше 64,81: пожилые, не ошибка

Гистограмма Fare





Почти все дешёвые, максимум 512

Boxplot Fare



Выше 65,63: дорогие, проверить

04 Что с чем связано



0,41

SibSp и Parch: семьи ехали вместе

537 из 891 ехали одни

Связь не значит, что одно вызывает другое

38% выжили (342 из 891)

65% мужчины

55% 3-й класс

05 Проблемы и план

НАШЁЛ

СДЕЛАЮ НА СЛЕДУЮЩЕМ ЗАНЯТИИ

Age: 177 пропусков

медиана + отметка «возраст неизвестен»

Cabin: 687 пропусков

признак «есть каюта»

Embarked: 2 пропуска

самый частый порт

Fare: дорогие билеты и цена 0

проверить, сравнить с $\log_{1p}(\text{Fare})$

Name, Ticket, PassengerId

не брать в первую модель

Выживших меньше: 342 / 549

стратификация, не только accuracy

Медиану и масштабирование считаю только на обучающей части, иначе утечка данных.

Пока ничего не удалял и не заполнял.