МАШИННОЕ ОБУЧЕНИЕ · ПР-8

Градиентный бустинг: прогноз оттока абонентов

Задача: по данным абонента предсказать, уйдёт ли он от оператора (churn = 1) или останется (churn = 0).

3000
абонентов в датасете

11
признаков: регион, тариф, стаж, звонки в поддержку…

37%
ушли: классы несбалансированы

80 / 20
train / test, как в ПР-7

Что сделали

ВЕХИ 8.1–8.2

Бустинг против леса

XGBoost по шаблону (300 деревьев) против леса из ПР-7. Метрики считает одна функция.

ВЕХА 8.4

Валидация из train

Выделил из train 20% под валидацию: 1920 / 480 строк. Test не трогал до самого конца.

ВЕХА 8.5

Ранняя остановка

Стоп, если 50 деревьев подряд не улучшают logloss на val. Хватило 79 деревьев вместо 300.

ВЕХА 8.6

Перебор параметров

12 комбинаций шага и глубины. Лучшая: lr = 0.05, depth = 3, 127 деревьев.

ВЕХА 8.3 · ГЛАВНОЕ ОТЛИЧИЕ ОТ ЛЕСА

В лесу деревья строятся независимо, в бустинге — по очереди: каждое исправляет ошибки прошлых. Поэтому лишние деревья ведут к переобучению и нужна ранняя остановка.

Итог: сравнение на одном разбиении

Модель	F1 train	F1 test	ROC-AUC test
Логрегрессия (лучшая)	0.594	0.611	0.806
XGBoost, подобранный	0.645	0.586	0.792
XGBoost, шаблон	0.789	0.574	0.779
Случайный лес, 100	1.000	0.556	0.752

Test: 600 абонентов. Метрики F1 и ROC-AUC, потому что классы несбалансированы.

ПОДБОР ПОМОГ

Разрыв F1 train/test у XGBoost: 0.215 → 0.059

ЛЕС ЗАПОМНИЛ TRAIN

F1 train = 1.000, на test хуже всех

ВЫВОД

Бустинг не всегда лучше: здесь зависимость почти линейная, и простая логрегрессия выигрывает.